

Dendê Preprocessing

Dendê Softhouse LTDA

Autores:

Carlos Henrique de Souza Santana Santiago

Gustavo Bezerra Nonato

Hudnei Sued Passos Santana

João Guilherme Gonçalves Pinheiro

Agenda

Nesta apresentação, passaremos pelo problema de negócios da Dendê Softhouse, a arquitetura da nossa biblioteca, a explicação técnica das 4 frentes de pré-processamento e, por fim, a aplicação real desses algoritmos no dataset do Spotify.

1. O Desafio: A dor da Dendê Softhouse.

2. Arquitetura Técnica:
Algoritmo de Pré-processamento de dados

3. Limpeza: Tratamento de duplicatas e nulos.

4. Transformadores de Escala:
Matemática contra o viés numérico.

5. Codificadores Categóricos:
Traduzindo textos para a máquina.

6. Aplicação Prática:
O pipeline rodando no Spotify.

O Desafio de Negócio: Motor da Dende Softhouse



O Objetivo da Dendê:

Criar um motor de
recomendação.


O Desafio de Negócio: Motor da Dende Softhouse



Machine Learning depende
100% da qualidade dos
dados.



O Desafio de Negócio: Motor da Dende Softhouse




O Risco de Negócio:

Dados brutos e ruidosos
geram recomendações
irrelevantes.

O Desafio de Negócio: Motor da Dende Softhouse

O Impacto:

Frustração do usuário final
e perda de engajamento
na nossa plataforma.



A Nossa Matéria-Prima



A Base de Treinamento:

Dataset real do Spotify com 8.582 músicas.

```
Carregando dados do Spotify...
```

```
Carregando dados de: src/data/spotify_data_clean.csv
```

```
✓ Leitura concluída! 8582 linhas processadas.
```

A base bruta é caótica e inviável para IA.

Problemas Encontrados:

Lacunas: ~40% de dados ausentes (Ex: gêneros musicais nulos).

Ruído: Registros duplicados.

Distorção: Escalas matemáticas incomparáveis (Duração em milissegundos vs. Popularidade de 0 a 100).

```
.[Drop Duplicates]: 2 linhas duplicadas
```



```
Moda de 'artist_genres': ['N/A']
```

```
○ Histograma de Duração (5 bins): {(0.07, 2.75799999999999996):
```

```
Quartis de Popularidade: {'Q1': 39.0, 'Q2': 58.0, 'Q3': 71.0}
```


Arquitetura Técnica

unex



Dendê Preprocessing - Dende Softhouse - Equipe Lauro




A Nossa Solução Interna

Uma biblioteca de pré-processamento.



100% Nativo

unex



Knowledge Discovery in Databases




Figura 1: Etapas do Processo KDD (Knowledge Discovery in Databases).
Fonte: DevMedia ([s.d.]).



Preprocessing

- Interface única usando o padrão de projeto Facade. Oculta a complexidade das listas nativas



Preprocessing



Módulo de Limpeza (MissingValueProcessor):

- Técnicas: Exclusão sumária (Dropna / Listwise) e Imputação estatística (Fillna por média ou mediana).



Preprocessing

MissingValueProcessor

Módulo de Escalonamento (Scaler):

- Técnicas: Normalização linear (Min-Max Scaler) e Padronização robusta a outliers (Z-Score)



A Arquitetura da Solução



Preprocessing

MissingValueProcessor

Scaler

Módulo de Tradução (Encoder):


- Técnicas: Numeração sequencial (Label Encoding) e Matrizes binárias (One-Hot Encoding).

Limpeza (Duplicatas e Nulls)

```
--- ANTES: DADOS BRUTOS (Com Duplicatas e Nulos) ---
ID      | MÚSICA                | ARTISTA          | GÊNERO
-----|-----|-----|-----
137     | Dracula               | Tame Impala      | australian psych
138     | Let It Happen         | Tame Impala      | australian psych
138     | Let It Happen         | Tame Impala      | australian psych
1807    | Never Felt So Alone   | Labrinth         | None
3EJ5    | Trippy Mane           | Diplo            | moombahton
```

```
[Sistema]: Iniciando orquestração via Facade...
[Drop Duplicates]: 1 linhas duplicadas foram para o lixo.
[Fill NA]: Missing values filled with Desconhecido.
```

```
--- DEPOIS: DADOS HIGIENIZADOS (Prontos para IA) ---
ID      | MÚSICA                | ARTISTA          | GÊNERO
-----|-----|-----|-----
137     | Dracula               | Tame Impala      | australian psych
138     | Let It Happen         | Tame Impala      | australian psych
1807    | Never Felt So Alone   | Labrinth         | Desconhecido
3EJ5    | Trippy Mane           | Diplo            | moombahton
```



1. SCANNER DE DUPLICATAS

Remove registros idênticos para evitar vieses de "peso dobrado" no algoritmo.

—	—	—
—	—	—
—	—	—
—	—	—
—	—	—





2. IMPUTAÇÃO DE NULOS (None)

Injeta "Desconhecido" em vez de deletar linhas (Dropna), preservando 100% do volume para treino.

	None	None
	None	NaN
	None	NaN
	NaN	None
	NaN	NaN



	Desconhecido
	Desconhecido
	Desconhecido
	Desconhecido
	Desconhecido

Limpeza (Duplicatas e Nulls)

```
--- INICIANDO PIPELINE DE PRÉ-PROCESSAMENTO ---
```

```
[Etapa 1]: Removendo duplicatas...
```

```
[Drop Duplicates]: 0 linhas duplicadas foram para o lixo.
```

```
[Etapa 2]: Tratando valores ausentes (NaN)...
```

```
✓ Pipeline Completo executado com sucesso!
```

```
📊 [Resumo]: O dataset entrou com 15 colunas e saiu  
com 17 colunas (devido ao One-Hot Encoding).
```

Por que usar?


Variáveis gigantes (milhões de seguidores) esmagam variáveis pequenas (minutos de duração).



Sem tratamento, o modelo de recomendação sofre de "viés de grandeza".

1. Min-Max Scaler (Aplicado em Seguidores):

Comprime limites extremos em uma escala estrita de 0 a 1.



$$X_{scaled} = \frac{X + X_{min}}{X_{max} - X_{min}}$$

Transformadores de Escala

X_{scaled} : O novo valor gerado (espremido entre 0 e 1).


X : O valor original da linha (ex: 38 milhões de seguidores).

X_{min} / X_{max} : O menor e o maior valor de toda a coluna.



2. Standard Scaler / Z-Score (Aplicado em Duração):

$$Z = \frac{X - \mu}{\sigma}$$



Centraliza os dados na média (0) e ajusta pelo desvio padrão. Ideal para lidar com variações normais e outliers.



Z: O novo valor gerado (diz se está acima ou abaixo da média).

X: O valor original da linha (ex: 3 minutos).

μ (Mi): A Média de toda a coluna.

σ (Sigma): O Desvio Padrão (mostra o quanto os valores variam entre si).

--- ANTES: 0 Risco do Viés Matemático ---

ARTISTA	DURAÇÃO (min)	SEGUIDORES

Diplo	3.5000	38000000.0000
Banda Local	4.1000	1500.0000
Artista Médio	2.8000	500000.0000

[Sistema]: Aplicando Z-Score em 'Duração' e Min-Max em 'Seguidores'...

--- DEPOIS: Escalas Equalizadas (Sem Viés) ---

ARTISTA	DURAÇÃO (min)	SEGUIDORES

Diplo	0.0627	1.0000
Banda Local	1.1922	0.0000
Artista Médio	-1.2549	0.0131

Problema: Os modelos de inteligência artificial apenas compreendem números, não sabem por exemplo o que são “Porto” ou “Lauro”.

Solução: Os codificadores(Encoders) transformam os textos em representações matemáticas para o modelo conseguir calcular, sem perder o significado da informação.

Codificadores categóricos

Dado original	Label encoding	One-Hot (Salvador)	One-Hot (Lauro)
Salvador	1	1	0
Lauro	0	0	1
Salvador	1	1	0

Codificadores categóricos



Label encoding

Usado Quando existe uma ordem ou hierarquia natural nos dados

Limitação do Label Encoding:

cria falsas grandezas. Se usarmos em cidades, a IA vai calcular erroneamente que a cidade "2" vale o dobro da cidade "1".

One-Hot

Usado Quando não existe hierarquia. Isso Garante que a IA trate todas as opções com o mesmo peso.

Limitação do One-Hot:

cria uma nova coluna para cada categoria diferente, pesando o sistema.

Aplicação Prática (Spotify)

```
--- INICIANDO PIPELINE DE PRÉ-PROCESSAMENTO ---
```

```
[Etapa 1]: Removendo duplicatas...
```

```
[Drop Duplicates]: 0 linhas duplicadas foram para o lixo.
```

```
[Etapa 2]: Tratando valores ausentes (NaN)...
```

```
[Etapa 3]: Aplicando Transformadores de Escala...
```

```
[Etapa 4]: Aplicando Encoders (Textos para Números)...
```

```
✅ Pipeline Completo executado com sucesso!
```

```
📊 [Resumo]: O dataset entrou com 15 colunas e saiu com 17 colunas (devido ao One-Hot Encoding).
```

```
📊 [Resumo]: Linhas finais prontas para o Machine Learning: 8582.
```


Aplicação Prática (Spotify)

```
--- AMOSTRA DO DATASET FINAL (Linha 0) ---  
track_id: 3EJS5LyekDim1Tf5rBFmZ1  
track_name: Trippy Mane (ft. Project Pat)  
track_number: 4  
track_popularity: 0.0  
explicit: 1  
artist_name: Diplo  
artist_popularity: 77  
artist_followers: 0.019326506242838156  
artist_genres: moombahton
```

Aplicação Prática (Spotify)

--- ANTES: Dados Reais do Spotify (Em Texto) ---

track_id	artist_name	album_type
----------	-------------	------------

3EJS5LyekD	Diplo	album
1oQW6G2Ziw	Yelawolf	single
7mdkjzoIYl	Riff Raff	single
67rW0Zl7oB	Diplo	album

[Sistema]: Acionando Facade Dendê Preprocessing...

[Motor]: Executando motor.encode(columns={'album_type'}, method='oneHot')

--- DEPOIS: Matriz Binária Pronta para Machine Learning ---

track_id	artist_name	album_type_album	album_type_single
----------	-------------	------------------	-------------------

3EJS5LyekD	Diplo	1	0
1oQW6G2Ziw	Yelawolf	0	1
7mdkjzoIYl	Riff Raff	0	1
67rW0Zl7oB	Diplo	1	0

Ilustração do one hot Encoding

- O desenvolvimento manual exigiu o domínio profundo das estruturas de dados e da base matemática que sustentam os algoritmos.
- A construção de um fluxo contínuo e estruturado, garantindo que as etapas de limpeza, padronização e codificação operem em perfeita sincronia.
- O motor cumpre seu papel de ponta a ponta: recebe o dado bruto do Spotify e entrega uma matriz higienizada, sem vieses e pronta para a Inteligência Artificial.

- DEVMEDIA. Mineração de Dados Educacionais usando KDD – Parte 1. DevMedia. Disponível em: <https://www.devmedia.com.br/mineracao-de-dados-educacionais-usando-kdd-parte-1/28968>. Acesso em: 24 mar. 2026.
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 9ª ed. São Paulo: Saraiva, 2017.
- HAN, J.; KAMBER, M.; PEI, J. Data Mining: Concepts and Techniques. 3ª ed. Morgan Kaufmann, 2011.
- PYTHON SOFTWARE FOUNDATION. Python Language Reference, version 3.x. Disponível em: <https://docs.python.org>. Acesso em: mar. 2026.