

# **Dendê Preprocessing**

# **Dendê Softhouse LTDA**

**Autores:**

Carlos Henrique de Souza Santana Santiago

Gustavo Bezerra Nonato

Hudnei Sued Passos Santana

João Guilherme Gonçalves Pinheiro

# Agenda

Nesta apresentação, passaremos pelo problema de negócios da Dendê Softhouse, a arquitetura da nossa biblioteca, a explicação técnica das 4 frentes de pré-processamento e, por fim, a aplicação real desses algoritmos no dataset do Spotify.

**1. O Desafio:** A dor da Dendê Softhouse.

**2. Arquitetura Técnica:**  
Algoritmo de Pré-processamento de dados

**3. Limpeza:** Tratamento de duplicatas e nulos.

**4. Transformadores de Escala:**  
Matemática contra o viés numérico.

**5. Codificadores Categóricos:**  
Traduzindo textos para a máquina.

**6. Aplicação Prática:**  
O pipeline rodando no Spotify.

# O Desafio de Negócio: Motor da Dende Softhouse



## O Objetivo da Dendê:

Criar um motor de  
recomendação.


# O Desafio de Negócio: Motor da Dende Softhouse



Machine Learning depende  
**100%** da qualidade dos  
dados.



# O Desafio de Negócio: Motor da Dende Softhouse



## O Risco de Negócio:


Dados brutos e ruidosos  
geram recomendações  
irrelevantes.



# O Desafio de Negócio: Motor da Dende Softhouse

## O Impacto:

Frustração do usuário final  
e perda de engajamento  
na nossa plataforma.



## A Base de Treinamento:

Dataset real do Spotify com 8.582 músicas.

```
Carregando dados do Spotify...
```

```
Carregando dados de: src/data/spotify_data_clean.csv
```

```
✓ Leitura concluída! 8582 linhas processadas.
```

A base bruta é caótica e inviável para IA.



## Problemas Encontrados:

Lacunas: ~40% de dados ausentes (Ex: gêneros musicais nulos).

Ruído: Registros duplicados.

Distorção: Escalas matemáticas incomparáveis (Duração em milissegundos vs. Popularidade de 0 a 100).

```
.[Drop Duplicates]: 2 linhas duplicadas
```

```
Moda de 'artist_genres': ['N/A']
```



```
○ Histograma de Duração (5 bins): {(0.07, 2.7579999999999996):
```

```
Quartis de Popularidade: {'Q1': 39.0, 'Q2': 58.0, 'Q3': 71.0}
```



# Arquitetura Técnica

unex



Dendê Preprocessing – Dende Softhouse – Equipe Lauro




# A Nossa Solução Interna

Uma biblioteca de pré-processamento.



100% Nativo

unex



# Knowledge Discovery in Databases




Figura 1: Etapas do Processo KDD (Knowledge Discovery in Databases).  
Fonte: DevMedia ([s.d.]).



## Preprocessing

- Interface única usando o padrão de projeto Facade.  
Oculta a complexidade das listas nativas



## Preprocessing

Módulo de Limpeza (MissingValueProcessor):

- Técnicas: Exclusão sumária (Dropna / Listwise) e Imputação estatística (Fillna por média ou mediana).





## Preprocessing

MissingValueProcessor

Módulo de Escalonamento (Scaler):

- Técnicas: Normalização linear (Min-Max Scaler) e Padronização robusta a outliers (Z-Score)



## Preprocessing

MissingValueProcessor

Scaler

Módulo de Tradução (Encoder):

- Técnicas: Numeração sequencial (Label Encoding) e Matrizes binárias (One-Hot Encoding).




# Limpeza (Duplicatas e Nulls)

```
--- ANTES: DADOS BRUTOS (Com Duplicatas e Nulos) ---
ID      | MÚSICA                | ARTISTA          | GÊNERO
-----|-----|-----|-----
137     | Dracula                | Tame Impala      | australian psych
138     | Let It Happen          | Tame Impala      | australian psych
138     | Let It Happen          | Tame Impala      | australian psych
1807    | Never Felt So Alone    | Labrinth         | None
3EJ5    | Trippy Mane            | Diplo            | moombahton
```

```
[Sistema]: Iniciando orquestração via Facade...
[Drop Duplicates]: 1 linhas duplicadas foram para o lixo.
[Fill NA]: Missing values filled with Desconhecido.
```

```
--- DEPOIS: DADOS HIGIENIZADOS (Prontos para IA) ---
ID      | MÚSICA                | ARTISTA          | GÊNERO
-----|-----|-----|-----
137     | Dracula                | Tame Impala      | australian psych
138     | Let It Happen          | Tame Impala      | australian psych
1807    | Never Felt So Alone    | Labrinth         | Desconhecido
3EJ5    | Trippy Mane            | Diplo            | moombahton
```



## 1. SCANNER DE DUPLICATAS

Remove registros idênticos para evitar vieses de "peso dobrado" no algoritmo.

| — | — | — |
|---|---|---|
| — | — | — |
| — | — | — |
| — | — | — |
| — | — | — |







## 2. IMPUTAÇÃO DE NULOS (None)

Injeta "Desconhecido" em vez de deletar linhas (Dropna), preservando 100% do volume para treino.

|  | None | None |
|--|------|------|
|  | None | NaN  |
|  | None | NaN  |
|  | NaN  | None |
|  | NaN  | NaN  |



|  | Desconhecido |
|--|--------------|
|  | Desconhecido |
|  | Desconhecido |
|  | Desconhecido |
|  | Desconhecido |

# Limpeza (Duplicatas e Nulls)

```
--- INICIANDO PIPELINE DE PRÉ-PROCESSAMENTO ---
```

```
[Etapa 1]: Removendo duplicatas...
```

```
[Drop Duplicates]: 0 linhas duplicadas foram para o lixo.
```

```
[Etapa 2]: Tratando valores ausentes (NaN)...
```

```
✅ Pipeline Completo executado com sucesso!
```

```
📊 [Resumo]: O dataset entrou com 15 colunas e saiu  
com 17 colunas (devido ao One-Hot Encoding).
```

## Por que usar?


Variáveis gigantes (milhões de seguidores) esmagam variáveis pequenas (minutos de duração).



Sem tratamento, o modelo de recomendação sofre de "viés de grandeza".

## 1. Min-Max Scaler (Aplicado em Seguidores):

Comprime limites extremos em uma escala estrita de 0 a 1.



$$X_{scaled} = \frac{X + X_{min}}{X_{max} - X_{min}}$$



# Transformadores de Escala

**$X_{\text{scaled}}$** : O novo valor gerado (espremido entre 0 e 1).


**$X$** : O valor original da linha (ex: 38 milhões de seguidores).

**$X_{\text{min}}$  /  $X_{\text{max}}$** : O menor e o maior valor de toda a coluna.



## 2. Standard Scaler / Z-Score (Aplicado em Duração):

$$Z = \frac{X - \mu}{\sigma}$$



Centraliza os dados na média (0) e ajusta pelo desvio padrão. Ideal para lidar com variações normais e outliers.





**Z:** O novo valor gerado (diz se está acima ou abaixo da média).

**X:** O valor original da linha (ex: 3 minutos).

**$\mu$  (Mi):** A Média de toda a coluna.

**$\sigma$  (Sigma):** O Desvio Padrão (mostra o quanto os valores variam entre si).



--- ANTES: 0 Risco do Viés Matemático ---

| ARTISTA       | DURAÇÃO (min) | SEGUIDORES    |
|---------------|---------------|---------------|
| Diplo         | 3.5000        | 38000000.0000 |
| Banda Local   | 4.1000        | 1500.0000     |
| Artista Médio | 2.8000        | 500000.0000   |

[Sistema]: Aplicando Z-Score em 'Duração' e Min-Max em 'Seguidores'...

--- DEPOIS: Escalas Equalizadas (Sem Viés) ---

| ARTISTA       | DURAÇÃO (min) | SEGUIDORES |
|---------------|---------------|------------|
| Diplo         | 0.0627        | 1.0000     |
| Banda Local   | 1.1922        | 0.0000     |
| Artista Médio | -1.2549       | 0.0131     |

**Problema:** Os modelos de inteligência artificial apenas compreendem números, não sabem por exemplo o que são “Porto” ou “Lauro”.

**Solução:** Os codificadores(Encoders) transformam os textos em representações matemáticas para o modelo conseguir calcular, sem perder o significado da informação.

# Codificadores categóricos

| Dado original | Label encoding | One-Hot (Salvador) | One-Hot (Lauro) |
|---------------|----------------|--------------------|-----------------|
| Salvador      | 1              | 1                  | 0               |
| Lauro         | 0              | 0                  | 1               |
| Salvador      | 1              | 1                  | 0               |

# Codificadores categóricos



## Label encoding

**Usado Quando existe uma ordem ou hierarquia natural nos dados**

### Limitação do Label Encoding:

cria falsas grandezas. Se usarmos em cidades, a IA vai calcular erroneamente que a cidade "2" vale o dobro da cidade "1".

## One-Hot

**Usado Quando não existe hierarquia. Isso Garante que a IA trate todas as opções com o mesmo peso.**

### Limitação do One-Hot:

cria uma nova coluna para cada categoria diferente, pesando o sistema.

# Aplicação Prática (Spotify)

```
--- INICIANDO PIPELINE DE PRÉ-PROCESSAMENTO ---
```

```
[Etapa 1]: Removendo duplicatas...
```

```
[Drop Duplicates]: 0 linhas duplicadas foram para o lixo.
```

```
[Etapa 2]: Tratando valores ausentes (NaN)...
```

```
[Etapa 3]: Aplicando Transformadores de Escala...
```

```
[Etapa 4]: Aplicando Encoders (Textos para Números)...
```

```
✅ Pipeline Completo executado com sucesso!
```

```
📊 [Resumo]: O dataset entrou com 15 colunas e saiu com 17 colunas (devido ao One-Hot Encoding).
```

```
📊 [Resumo]: Linhas finais prontas para o Machine Learning: 8582.
```



# Aplicação Prática (Spotify)

```
--- AMOSTRA DO DATASET FINAL (Linha 0) ---  
track_id: 3EJS5LyekDim1Tf5rBFmZ1  
track_name: Trippy Mane (ft. Project Pat)  
track_number: 4  
track_popularity: 0.0  
explicit: 1  
artist_name: Diplo  
artist_popularity: 77  
artist_followers: 0.019326506242838156  
artist_genres: moombahton
```

# Aplicação Prática (Spotify)

--- ANTES: Dados Reais do Spotify (Em Texto) ---

| track_id | artist_name | album_type |
|----------|-------------|------------|
|----------|-------------|------------|

|            |           |        |
|------------|-----------|--------|
| 3EJS5LyekD | Diplo     | album  |
| 1oQW6G2Ziw | Yelawolf  | single |
| 7mdkjzoIYl | Riff Raff | single |
| 67rW0Zl7oB | Diplo     | album  |

[Sistema]: Acionando Facade Dendê Preprocessing...

[Motor]: Executando motor.encode(columns={'album\_type'}, method='oneHot')

--- DEPOIS: Matriz Binária Pronta para Machine Learning ---

| track_id | artist_name | album_type_album | album_type_single |
|----------|-------------|------------------|-------------------|
|----------|-------------|------------------|-------------------|

|            |           |   |   |
|------------|-----------|---|---|
| 3EJS5LyekD | Diplo     | 1 | 0 |
| 1oQW6G2Ziw | Yelawolf  | 0 | 1 |
| 7mdkjzoIYl | Riff Raff | 0 | 1 |
| 67rW0Zl7oB | Diplo     | 1 | 0 |

Ilustração do one hot Encoding

- O desenvolvimento manual exigiu o domínio profundo das estruturas de dados e da base matemática que sustentam os algoritmos.
- A construção de um fluxo contínuo e estruturado, garantindo que as etapas de limpeza, padronização e codificação operem em perfeita sincronia.
- O motor cumpre seu papel de ponta a ponta: recebe o dado bruto do Spotify e entrega uma matriz higienizada, sem vieses e pronta para a Inteligência Artificial.



- DEVMEDIA. Mineração de Dados Educacionais usando KDD – Parte 1. DevMedia. Disponível em: <https://www.devmedia.com.br/mineracao-de-dados-educacionais-usando-kdd-parte-1/28968>. Acesso em: 24 mar. 2026.
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 9ª ed. São Paulo: Saraiva, 2017.
- HAN, J.; KAMBER, M.; PEI, J. Data Mining: Concepts and Techniques. 3ª ed. Morgan Kaufmann, 2011.
- PYTHON SOFTWARE FOUNDATION. Python Language Reference, version 3.x. Disponível em: <https://docs.python.org>. Acesso em: mar. 2026.